



الجمهورية العربية السورية

جامعة الحواش الخاصة

كلية الهندسة

قسم الهندسة المعلوماتية

تطبيق موبايل لكشف تزوير العملة النقدية باستخدام تقنيات

الذكاء الاصطناعي وتعلم الآلة

مشروع تخرج أعد لنيل درجة الإجازة في الهندسة - قسم المعلوماتية

إعداد الطلاب

علي عدنان محمد

مجد سامر خليفة

بإشراف

د. م. محمد ديب

العام الدراسي

2026-2025

الملخص

تمثل ظاهرة تزوير الأوراق النقدية تهديداً مستمراً للاستقرار الاقتصادي والأمني، ومع تطور تقنيات الطباعة الرقمية، برزت الحاجة الماسة لتطوير أنظمة تحقق ذكية وسهلة الاستخدام وقابلة للوصول من قبل المستخدمين العاديين والخبراء على حد سواء. يهدف هذا المشروع إلى بناء نظام برمجي متكامل (عميل/خادم) يتجلى في تطبيق هاتف محمول مخصص للكشف الذكي عن تزوير الفئات النقدية للعملة السورية.

تعتمد خطة العمل على معالجة البيانات على مرحلتين أساسيتين، تتضمن المرحلة الأولى هندسة البيانات وتنقيتها برمجياً، حيث تم بناء وحدة محاذاة وقص تلقائي معتمدة على خوارزمية تحويل الميزات غير المتغيرة مع المقياس (SIFT) وحساب مصفوفة التجانس (Homography) لضمان عزل العملة النقدية عن الخلفيات العشوائية وتوحيد أبعادها بدقة وثبات. وتتضمن المرحلة الثانية مرحلة الاستنتاج والتعلم الشامل، حيث تم تطوير شبكة عصبية عميقة من نوع المشفر التلقائي التلافيفي العميق (DeepCAE) المعزز بطبقات التسوية بالدفعات (BatchNorm) والإسقاط (Dropout) لتجنب الإفراط في الملاءمة. تم تدريب النموذج ككاشف شذوذ (Anomaly Detector) على البنى الهيكلية والنسجية الدقيقة للأوراق النقدية الحقيقية فقط، ليقوم بحساب الخطأ في إعادة البناء كميّار للفرز والتصنيف. ولتحقيق مبدأ قابلية التفسير في الذكاء الاصطناعي (XAI)، تم دمج خوارزمية (Grad-CAM) لتوليد خرائط حرارية مرئية توضح للمستخدم بدقة مواضع الخلل العالية التي تسببت في تصنيف الورقة كمزورة.

أظهرت النتائج التجريبية كفاءةً واستقراراً عالياً في منحنيات التعلم والتحقق، حيث استقر النظام عند عتبة تصنيف نهائية صارمة للخطأ المتوسط للجذر التربيعي بلغت (0.06907). أثبتت هذه العتبة قدرة فائقة على اصطياد التزوير بدقة متناهية وفصل التشويشات والعيوب عالية التردد في العملات المزيفة والبطاقات المسووعة ضوئياً مع تقديم تفسيرات بصرية ممتازة. تم بناء المعمارية البرمجية للنظام بتكامل تام، حيث تم تطوير الواجهات الأمامية لتطبيق الهاتف المحمول باستخدام إطار العمل (Flutter)، بينما تم بناء السيرفر الخلفي لإدارة العمليات والذكاء الاصطناعي باستخدام إطار (Django REST Framework) بلغة البايثون (Python)، مما يضمن توزيعاً برمجياً مرناً وصلاحيات أمان متطورة تناسب فئات المستخدمين المختلفة.

فهرس المحتويات

i	الملخص
ii	فهرس المحتويات
i	فهرس الأشكال
i	فهرس الجداول
1	1 الفصل الأول: المقدمة
1.1	1.1 مقدمة
2.1	2.1 فكرة المشروع والهدف منه
3.1	3.1 أهمية المشروع والجهات المستفيدة
2	2 الفصل الثاني: الدراسة النظرية
1.2	1.2 الرؤية الحاسوبية واستخراج الميزات
2.2	2.2 التعلم العميق والمشفرات التلقائية (Deep Learning & Autoencoders)
3.2	3.2 الذكاء الاصطناعي القابل للتفسير وخوارزمية (Grad-CAM)
4.2	4.2 محاكاة التزوير الاصطناعي (Artificial Forgery)
5.2	5.2 مقاييس تقييم الأداء (Evaluation Metrics)
6.2	6.2 أطر العمل والتقنيات المستخدمة (Frameworks)
7.2	7.2 الدراسات السابقة والأبحاث المرجعية (Literature Review)
1.7.2	1.7.2 الدراسات المعتمدة على التصنيف الثنائي (Binary Classification)
2.7.2	2.7.2 الدراسات المعتمدة على توليد البيانات وشبكات (GANs)
3.7.2	3.7.2 الدراسات المعتمدة على كشف الشذوذ وقابلية التفسير (Anomaly Detection &)
9	(XAI)

4.7.2	أوجه التميز ومساهمة المشروع الحالي (Systematic Comparison &)	9
3	الفصل الثالث: التطبيق العملي وتحليل النظام	10
1.3	تجميع وبناء مجموعة البيانات	10
2.3	تحليل النظام والمخططات الهندسية	10
1.2.3	مخطط حالات الاستخدام (Use Case Diagram)	10
2.2.3	مخطط البنية التحتية للنظام (System Architecture Diagram)	11
3.2.3	مخطط قاعدة البيانات	12
4.2.3	مخطط التتابع الشامل (System Sequence Diagram)	13
5.2.3	مخطط تدفق عمليات الذكاء الاصطناعي (AI Pipeline)	14
6.2.3	مخطط سير العمل العام (General System Workflow)	15
7.2.3	مخطط سير عمل المعالجة الذكية (AI Algorithm Workflow)	17
8.2.3	مخطط الصفوف (Class Diagram)	17
3.3	واجهات التطبيق	18
1.3.3	واجهات الترحيب والمصادقة (Onboarding & Authentication)	19
2.3.3	واجهات المستخدم الأساسية وعمليات الفحص (Core User Interfaces &)	22
3.3.3	واجهات الخبراء والتحليل المتقدم (Expert Screens & Advanced Analysis)	27
4.3.3	واجهات الزائر والقيود البرمجية (Guest Screens & Access Limitations)	30
5.3.3	واجهات مدير النظام ولوحة التحكم المركزية (Admin Dashboard & Control)	31
4.3	أمن النظام وحماية البيانات	37

37	1.4.3 أمن واجهات برمجة التطبيقات (API Security & Authentication)
38	2.4.3 التحكم بالوصول ومكافحة الإغراق (RBAC & Rate Limiting)
	3.4.3 خصوصية البيانات ومعالجة الصور المتطايرة (Volatile Image Processing)
38	
39	4 الفصل الرابع: النتائج والاختبارات
39	1.4 مقدمة
39	2.4 بيئة الاختبار والتدريب (Training & Testing Environment)
39	3.4 اختبارات المعالجة المسبقة والمحاذاة.....
42	4.4 مراحل تطور النموذج والمقارنة.....
42	1.4.4 النموذج الأولي (Simple CAE)
42	2.4.4 النموذج المتوسط (DeepCAE)
43	3.4.4 النموذج النهائي (DeepCAE + Clean Data)
43	5.4 تحليل مسار التطوير.....
43	6.4 تقييم أداء النموذج النهائي (Model Evaluation)
45	7.4 اختبارات قابلية التفسير (Grad-CAM Visual Explanations)
48	5 الفصل الخامس: الخاتمة والتوصيات المستقبلية.....
48	1.5 التحديات التي واجهت المشروع.....
48	2.5 الآفاق والتوصيات المستقبلية.....
49	3.5 الخاتمة
50	قائمة المصطلحات والاختصارات
51	المراجع References
52	Abstract

فهرس الأشكال

- الشكل (1-2): معمارية المشفر التلقائي التلافي العميق DeepCAE [10]. 4
- الشكل (1-3): مخطط حالات الاستخدام للنظام. 11
- الشكل (2-3): مخطط البنية التحتية وتدفق البيانات. 12
- الشكل (3-3): مخطط الكيانات والعلاقات لنموذج البيانات. 13
- الشكل (4-3): مخطط التتابع الشامل للنظام. 14
- الشكل (5-3): مخطط تتابع محرك الذكاء الاصطناعي. 15
- الشكل (6-3): مخطط سير العمل العام للنظام. 16
- الشكل (7-3): مخطط سير عمل الخوارزمية الذكية واتخاذ القرار. 17
- الشكل (8-3): مخطط الصفوف (Class Diagram) للبنية الكائنية للنظام ومحرك الذكاء الاصطناعي. 18
- الشكل (9-3): شاشة البداية توضح الهوية البصرية والتمهيد الأمني للتطبيق. 19
- الشكل (10-3): شاشات الترحيب والتعريف بميزات النظام. 20
- الشكل (11-3): واجهات المصادقة وتسجيل الدخول مع خيار الزائر. 21
- الشكل (12-3): الشاشة الرئيسية وواجهة الكاميرا مع إرشادات المسح الضوئي. 23
- الشكل (13-3): شاشات عرض النتيجة النهائية للعمليات الحقيقية والمزيفة. 24
- الشكل (14-3): واجهات السجل وتصفية الفحوصات السابقة. 25
- الشكل (15-3): واجهات الملف الشخصي والإحصائيات وإعدادات النظام. 26
- الشكل (16-3): واجهة تفاصيل المشروع توضح الملخص التنفيذي وحزمة التقنيات المستخدمة. 27
- الشكل (17-3): الشاشة الرئيسية والملف الشخصي المخصص لدور الخبير. 28
- الشكل (18-3): واجهات الفحص للخبير تبرز الخرائط الحرارية وأزرار التوثيق والإبلاغ. 29
- الشكل (19-3): واجهات الإبلاغ عن الأخطاء، تتبع التقارير، ومراقبة فحوصات المجتمع. 30
- الشكل (20-3): الشاشة الرئيسية للزائر والقيود البرمجية المفروضة على السجل. 31
- الشكل (21-3): لوحة المعلومات الرئيسية لحالة النظام. 32
- الشكل (22-3): واجهة إدارة هويات مستخدمي النظام وصلاحياتهم. 33
- الشكل (23-3): السجل الشامل لعمليات الفحص على مستوى الشبكة. 34

- الشكل (3-24): واجهة استقبال التغذية الراجعة وتقارير الخبراء. 35
- الشكل (3-25): واجهة التحكم الديناميكي بسياسات الصلاحيات. 36
- الشكل (3-26): واجهة التحكم بإعدادات المنصة المتقدمة. 37
- الشكل (4-1): أمثلة عملية لاختبارات SIFT توضح نجاح الخوارزمية في استخراج الميزات، تصحيح
الميلان، وقص العملات المأخوذة في ظروف عشوائية. 41
- الشكل (4-2): منحنيات الخسارة ودقة التحقق خلال 50 حقبة تدريبية. 44
- الشكل (4-3): مصفوفة الارتباك (Confusion Matrix). 45
- الشكل (4-4): التفسير البصري للذكاء الاصطناعي (Grad-CAM). 47

فهرس الجداول

جدول (1-4): مقارنة مراحل تطور نموذج كشف الشذوذ 42

الفصل الأول المقدمة

1.1 مقدمة

منذ ظهور العملات الورقية، شكلت عمليات التزوير والتزييف تحدياً مستمراً للاقتصادات العالمية ومصدر قلق دائم للحكومات والأفراد على حد سواء. ومع التطور المتسارع في تقنيات الطباعة الرقمية، والمساحات الضوئية عالية الدقة، وبرامج المعالجة الصورية، أصبحت عملية تزييف الأوراق النقدية أكثر احترافية ودقة، مما جعل من الصعب جداً على الأفراد العاديين التمييز بين العملة الحقيقية والمزيفة بالاعتماد على الحواس البشرية فقط أو حتى عبر أدوات الفحص التقليدية البسيطة كالأقلام الكيميائية. في هذا السياق، برز الذكاء الاصطناعي (Artificial Intelligence) وتحديداً تقنيات الرؤية الحاسوبية (Computer Vision) والتعلم العميق (Deep Learning) كحلول جذرية وموثوقة، فهذه التقنيات تمتلك قدرة فائقة على استخراج وتحليل أدق الخصائص الهيكلية والأنماط النسيجية الدقيقة للعملة والتي يستحيل على المزورين استنساخها بشكل تطابق تام [3].

2.1 فكرة المشروع والهدف منه

تتبلور فكرة هذا المشروع في تصميم وتطوير نظام برمجي متكامل، يتألف من تطبيق هاتف محمول (Application Mobile) مرتبط بخادم مركزي (Server) مدعوم بنماذج الذكاء الاصطناعي، يختص بكشف تزوير فئات العملة السورية بدقة وموثوقية عالية.

ويهدف المشروع بشكل رئيسي إلى تحقيق النقاط التالية:

- **المعالجة المسبقة والمحاذاة الدقيقة:** استخدام خوارزمية تحويل الميزات غير المتغيرة مع المقياس (SIFT) لاكتشاف النقاط المرجعية، بهدف عزل الورقة النقدية وقصها من الصور الملتقطة عشوائياً، مما يضمن استبعاد الخلفيات المشتتة وتوحيد أبعاد الإدخال.
- **كشف الشذوذ (Anomaly Detection):** بناء وتدريب شبكة عصبية عميقة من نوع المشفر التلقائي التلافيفي (DeepCAE) مُدربة حصرياً على الأوراق النقدية الحقيقية. يعتمد النظام على مبدأ "خطأ إعادة البناء (Reconstruction Error)"، حيث يتمكن النموذج من إعادة بناء الصور

الحقيقية بدقة، بينما يظهر خطأً رياضياً كبيراً عند محاولة إعادة بناء الصور المزيفة، مما يُتخذ كمعيار حاسم للتصنيف [1].

- **قابلية التفسير والشفافية (Explain ability):** دمج خوارزمية (Grad-CAM) لتوليد خرائط حرارية (Heatmaps) مرئية تُبرز للمستخدم مواضع الخلل الدقيقة في الورقة النقدية، مما يرفع من موثوقية النظام استناداً لمبادئ الذكاء الاصطناعي القابل للتفسير (XAI) [2].
- **توفير واجهة استخدام سلسة:** بناء تطبيق مرّن باستخدام إطار العمل (Flutter) يتيح للمستخدمين فحص العملات بكاميرا الهاتف الذكي لحظياً وبسهولة تامة.

3.1 أهمية المشروع والجهات المستفيدة

تتبع أهمية هذا المشروع من كونه يقدم حلاً تقنياً متطوراً وقابلاً للتطوير يساهم في حماية الاقتصاد الوطني من التضخم وآثاره السلبية الناتجة عن ضخ العملات المزيفة في الأسواق، فضلاً عن تقليص الخسائر المادية المباشرة التي يتعرض لها الأفراد والتجار. يمكن تصنيف الجهات المستفيدة من هذا النظام إلى الفئات التالية:

- **المواطنون العاديون:** حماية مدخراتهم وتعاملاتهم اليومية من عمليات الاحتيال من خلال توفير أداة موثوقة في متناول أيديهم عبر هواتفهم الذكية.
- **أصحاب الفعاليات التجارية (نقاط البيع، المتاجر، محطات الوقود):** تسريع وتسهيل عملية التحقق من النقد أثناء أوقات الذروة، دون الحاجة للاستثمار في أجهزة فحص تقليدية مكلفة أو بطيئة.
- **الجهات المالية والمصرفية:** يمكن استخدام النظام عبر واجهة الخبراء (Experts) كأداة رديفة للتحقق المزدوج، مع إمكانية توثيق النماذج الجديدة من العملات المزورة ورفعها للخادم، مما يساعد في التحديث المستمر للنموذج الأم.

الفصل الثاني الدراسة النظرية

1.2 الرؤية الحاسوبية واستخراج الميزات

تعتبر الرؤية الحاسوبية أحد أهم فروع الذكاء الاصطناعي التي تهدف إلى تمكين الآلات من فهم واستيعاب المحتوى المرئي في الصور والفيديوهات الرقمية. في سياق هذا المشروع، شكلت عملية عزل العملة النقدية عن الخلفيات العشوائية تحدياً برمجياً تطلب استخدام تقنيات استخراج ميزات متقدمة لضمان دقة الإدخال إلى شبكة التعلم العميق. لتحقيق ذلك، تم الاعتماد على خوارزمية تحويل الميزات غير المتغيرة مع المقياس (Scale-Invariant Feature Transform - SIFT). تعتمد الخوارزمية رياضياً على تحويل الصورة إلى مقياس (Scale-space) لاكتشاف "نقاط الاهتمام" (Keypoints) عبر طي الصورة الأصلية $I(x, y)$ مع مرشح غاوسي $G(x, y, \sigma)$ عند مقاييس مختلفة، وفق المعادلة:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \quad (1-2)$$

ثم يتم حساب فرق غاوسي (DoG) لاكتشاف النقاط القصوى التي تتميز بثباتها ضد تغيرات الحجم والإضاءة:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (2-2)$$

بعد استخراج ووصف هذه النقاط، يتم مطابقتها مع نقاط مرجعية لعملات أصلية مخزنة مسبقاً. ولعزل العملة هندسياً وتصحيح زوايا ميلانها، يقوم النظام بحساب مصفوفة التجانس (Homography Matrix H)، والتي تطبق تحويلاً هندسياً ينقل إحداثيات العملة من الصورة العشوائية إلى أبعاد قياسية مسطحة (Alignment) وفق العلاقة:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = H \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3-2)$$

مما يضمن قصاً دقيقاً ومطابقاً تماماً للأبعاد المطلوبة لشبكة الذكاء الاصطناعي [6, 8].


2.2 التعلم العميق والمشفرات التلقائية (Deep Learning & Autoencoders)

التعلم العميق هو مجموعة فرعية من تعلم الآلة تعتمد على الشبكات العصبية الاصطناعية متعددة الطبقات. لحل معضلة كشف التزوير، تم الابتعاد عن نماذج التصنيف التقليدية (Classification) التي تتطلب صوراً حقيقية ومزيفة للتدريب، والاعتماد بدلاً من ذلك على استراتيجيات كشف الشذوذ (Anomaly)

(Detection) باستخدام معمارية المشفر التلقائي التلافيفي العميق (Deep Convolutional Autoencoder-DeepCAE).

تتألف هذه المعمارية من جزأين رئيسيين:

- **المشفر (Encoder):** وظيفته استقبال صورة العملة النقدية وتمثيلها عبر سلسلة من الطبقات التلافيفية (Convolutional Layers) لضغطها واستخراج أهم الأنماط الهيكلية (كالزخارف والخطوط) وتمثيلها في فضاء كامن (Latent Space) منخفض الأبعاد.
- **فك التشفير (Decoder):** يقوم بالعملية العكسية، حيث يأخذ التمثيل المضغوط ويحاول إعادة بناء الصورة الأصلية بنفس أبعادها السابقة باستخدام طبقات التلافيف العكسي.



الشكل (1-2): معمارية المشفر التلقائي التلافيفي العميق DeepCAE [10].

تعتمد فكرة كشف التزوير على تدريب هذا النموذج حصرياً على بيانات (عملات حقيقية ونظيفة). ونتيجة لذلك، يتعلم النموذج فيزياء وزخارف العملة السورية بدقة. عند إدخال عملة حقيقية، سيتمكن الـ Decoder من إعادة بنائها بخطأ رياضي منخفض جداً. أما عند إدخال عملة "مزيفة" تحتوي على تشوهات أو تفاصيل طباعة رديئة لم يتدرب عليها النموذج مسبقاً، فسيفشل في إعادة بنائها بدقة، مما يؤدي إلى ارتفاع ملحوظ في قيمة "خطأ إعادة البناء (Reconstruction Error)" والذي يتم قياسه باستخدام متوسط مربع الخطأ (MSE) أو خطأ الجذر التربيعي المتوسط (RMSE). بناءً على قيمة هذا الخطأ ومقارنتها بعتبة رياضية مدروسة، يتخذ النظام قراره الحاسم بكون العملة حقيقية أم مزورة [7].

3.2 الذكاء الاصطناعي القابل للتفسير وخوارزمية (Grad-CAM)

لم يعد مقبولاً في الأنظمة الأمنية والمالية أن يعمل الذكاء الاصطناعي كـ "صندوق أسود" (Black Box) "يعطي نتيجة دون تبرير". لذلك، يندرج هذا المشروع تحت مظلة الذكاء الاصطناعي القابل للتفسير (Explainable AI-XAI). لتحقيق التفسير المرئي، تم توظيف خوارزمية (Gradient-weighted Class Activation Mapping - Grad-CAM). تعتمد هذه الخوارزمية رياضياً على حساب التدرجات (Gradients) للنتيجة الخاصة بفئة معينة (Y^c) بالنسبة لخرائط التنشيط (A^k) المتدفقة من الطبقة التلافيفية الأخيرة. يتم أولاً حساب الأوزان (α_k^c) التي تمثل الأهمية المكانية لكل خريطة ميزة في اتخاذ القرار (وهي تمثل في مشروعنا مناطق خطأ إعادة البناء العالية):

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial Y^c}{\partial A_{ij}^k} \quad (4-2)$$

ثم يتم توليد الخريطة الحرارية (Heatmap) بدمج هذه الأوزان خطياً وتمييرها عبر دالة التنشيط (ReLU) لإبراز المناطق ذات التأثير الإيجابي فقط في تصنيف الشذوذ:

$$L_{Grad-CAM^c} = ReLU(\sum_k \alpha_k^c A^k) \quad (5-2)$$

تُدمج هذه الحسابات مع الصورة الأصلية، حيث تظهر الألوان الدافئة (كالأحمر والأصفر) بدقة فوق أماكن التزوير أو التشويه في العملة، مما يقدم دليلاً بصرياً قاطعاً للمستخدم يفسر سبب رفض النظام للورقة النقدية [2].

4.2 محاكاة التزوير الاصطناعي (Artificial Forgery)

تعتبر ندرة البيانات الموثوقة من أكبر التحديات في بناء أنظمة كشف التزوير، حيث يمكن الحصول على صور للعملات الحقيقية بسهولة، بينما يُعد بناء قاعدة بيانات ضخمة وشاملة لعملات سورية مزورة أمراً بالغ الصعوبة. للتغلب على هذه المعضلة، تم تطبيق استراتيجية "محاكاة التزوير الاصطناعي" باستخدام تقنيات تعزيز البيانات (Data Augmentation). تم تصميم دوال رياضية برمجية لتحويل صور العملات الحقيقية إلى نسخ تحاكي بدقة الأخطاء الشائعة في عمليات التزوير باستخدام الطابعات التجارية العادية. شملت هذه التحويلات:

- التشوه اللوني (Color Jittering): تغيير قيم السطوع (Brightness) والتباين (Contrast) والإشباع اللوني (Saturation) لمحاكاة استخدام أحبار تجارية غير مطابقة للحبر الأمني الأصلي.
- التغبيش أو الضبابية (Gaussian Blur): تطبيق مرشحات ضبابية لمحاكاة دقة الطباعة المنخفضة (Low DPI) وضعف التفاصيل في الزخارف الدقيقة للورقة المزورة.
- الضجيج الورقي (Paper Noise): إضافة ضجيج عشوائي للبكسلات لمحاكاة الاختلاف في ملمس ونسيج الورق التجاري (الذي يعكس الضوء بشكل مختلف) مقارنة بورق القطن الأمني المستخدم في العملات الحقيقية. مكّنت هذه الاستراتيجية من توليد عينات مزيفة هندسياً لاختبار استقرار النموذج وقدرته على فصل الميزات وتحديد عتبة الخطأ (Threshold) الدقيقة [4].

5.2 مقاييس تقييم الأداء (Evaluation Metrics)

لتقييم أداء نموذج الذكاء الاصطناعي بشكل علمي دقيق، تم الاعتماد على مجموعة من المقاييس الإحصائية المستنبطة من مصفوفة الارتباك (Confusion Matrix). في سياق هذا النظام، يعتبر تصنيف العملة الحقيقية كإيجابي (Positive) والمزورة كسلب (Negative). شملت المقاييس:

- جذر متوسط مربع الخطأ (RMSE): المقياس الأساسي لحساب مقدار الفروقات في البكسلات بين الصورة الأصلية المدخلة والصورة التي أعاد المشفر التلقائي (DeepCAE) بناءها. ويُعبر عنه رياضياً بالمعادلة:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (6-2)$$

حيث (N) هو العدد الإجمالي للبكسلات، (x_i) قيمة البكسل في الصورة الأصلية، و $(\hat{x}_i)$ قيمة البكسل في الصورة المُعاد بناؤها.

- الدقة الإجمالية (Accuracy): النسبة المئوية للتنبؤات الصحيحة (حقيقية ومزورة) من إجمالي الصور المفحوصة:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (7-2)$$

- مؤشر التشابه البنيوي (SSIM): مقياس تم دمج مع دالة الخسارة لتقييم التدهور في جودة الصورة وإجبار الشبكة على التركيز على "الهيكل والزخارف" بدلاً من الألوان فقط.

- **الضبط (Precision):** يقيس مدى صحة النظام عندما يقرر أن العملة "حقيقية". أي أنه يقلل من نسبة الإيجابية الكاذبة (False Positive)، وهو أمر حساس لتجنب تمرير عملة مزورة على أنها حقيقية:

$$Precision = \frac{TP}{TP + FP} \quad (8-2)$$

- **الاستدعاء أو الحساسية (Recall):** يقيس قدرة النظام على اكتشاف جميع العملات الحقيقية من بين إجمالي العملات الحقيقية الفعلية في البيانات:

$$Recall = \frac{TP}{TP + FN} \quad (9-2)$$

- **مقياس (F1-Score):** يمثل المتوسط التوافقي بين الـ Precision والـ Recall، ويُعد المقياس الأفضل لتقييم كفاءة النموذج الشاملة خاصة عند وجود عدم توازن بين عدد الصور الحقيقية والمزورة في بيانات الاختبار.

6.2 أطر العمل والتقنيات المستخدمة (Frameworks)

لتحويل الخوارزميات الرياضية إلى نظام برمجي متكامل (عميل/خادم)، تم توظيف أحدث أطر العمل واللغات البرمجية المعتمدة في الصناعة:

- **بيئة بايثون ومكتبة بايتورتش (Python & PyTorch):** استُخدمت لغة بايثون كلغة أساسية لبرمجة الذكاء الاصطناعي، بينما تم الاعتماد على إطار العمل (PyTorch) مفتوح المصدر من جوجل/ميثا لبناء وهندسة المعمارية العميقة (DeepCAE) وتدريبها، نظراً لما يوفره من مرونة وسرعة في حساب التدرجات الآلية ومعالجة المصفوفات الضخمة (Tensors) باستخدام معالجات الرسومات (GPUs) [9].
- **إطار عمل جانغو (Django & Django REST Framework):** تم بناء الواجهة الخلفية (Backend) والخادم المركزي باستخدام إطار (Django) المكتوب بلغة بايثون. تكفل هذا الإطار بإدارة قواعد البيانات، وحماية النظام، وتوزيع وإدارة الأدوار البرمجية متعددة المستويات (Multi-tier Role-based Access Control) والتي تشمل أربعة أدوار أساسية: مدير النظام (Admin)، الخبير (Expert)، المستخدم المسجل (User)، والزائر (Guest). وتتجلى كفاءة الإطار في فرض سياسات فحص وقيود صارمة على دور الزائر (Guest)، حيث يُسمح له برمجياً بتحليل صورتين فقط كحد أقصى (يتم تتبعهما والتحقق منهما عبر معرف الجهاز المطور Device ID أو عنوان

الـ IP لتجربة النظام)، ليقوم السيرفر بعد ذلك بإلزام المستخدم بإنشاء حساب رسمي موثق للاستمرار في استخدام الخدمة. في حين استُخدم (DRF) لبناء واجهات برمجة التطبيقات (APIs) لاستقبال الصور الخام المشفرة، تمريرها إلى محرك الذكاء الاصطناعي، ثم إرجاع نتائج التحليل (مؤشر التزوير والخريطة الحرارية Base64) إلى التطبيق [12, 13, 14].

- إطار عمل فلاتر (Flutter): لبناء الواجهة الأمامية (Frontend)، تم استخدام Flutter ولغة Dart من جوجل. يسمح هذا الخيار البرمجي بتصدير تطبيق هاتف محمول مدمج وعالي الأداء يعمل بامتياز على أنظمة التشغيل المختلفة (Android & iOS) من كود مصدري واحد، مع توفير تجربة مستخدم (UX) تفاعلية وسلسلة لعملية المسح وعرض النتائج [11].

7.2 الدراسات السابقة والأبحاث المرجعية (Literature Review)

حظي مجال كشف تزوير العملات النقدية باستخدام تقنيات الذكاء الاصطناعي باهتمام بحثي واسع خلال السنوات الأخيرة. وقد سعت العديد من الدراسات إلى تطوير أنظمة قادرة على التمييز بين العملة الحقيقية والمزيفة بالاعتماد على تقنيات الرؤية الحاسوبية والتعلم العميق. يُستعرض فيما يلي أبرز الأبحاث ذات الصلة ومقارنتها بالمنهجية المتبعة في هذا المشروع:

1.7.2 الدراسات المعتمدة على التصنيف الثنائي (Binary Classification)

ركزت العديد من الأبحاث على استخدام الشبكات العصبية التلافيفية (CNNs) كأدوات تصنيف ثنائي. على سبيل المثال، قدم الباحثان (Hamed & Al Azzo, 2024) نظاماً لكشف تزوير العملات العراقية يعتمد على تقنيات التعلم العميق التقليدية [4]. ورغم تحقيق النظام لدقة جيدة، إلا أن هذا النهج يعاني من قصور جوهري يتمثل في الحاجة الماسة إلى وجود قاعدة بيانات ضخمة ومتوازنة تحتوي على صور لعملات مزيفة وحقيقية بظروف مثالية، وهو أمر يصعب تحقيقه في الواقع العملي نظراً لسرية وصعوبة تجميع عينات مزورة كافية. وبشكل مشابه، تناول بحث (Gebremeskel et al., 2022) تطوير نموذج للعملة الإثيوبية، والذي واجه تحديات مماثلة في تعميم النتائج على الصور الملتقطة بظروف إضاءة عشوائية [5].

2.7.2 الدراسات المعتمدة على توليد البيانات وشبكات (GANs)

لحل مشكلة نقص البيانات المزورة، اقترح (Ali et al., 2019) في دراستهم (DeepMoney) استخدام شبكات التوليد التنافسية (Networks - GANs Generative Adversarial) لتوليد صور اصطناعية لعملات مزيفة وتدريب النظام عليها [3]. يعتبر هذا الحل رياضياً متقدماً، لكنه يستهلك موارد حوسبة هائلة (High

(Computational Cost)، كما أن النظام الناتج يعمل كـ "صندوق أسود" لا يقدم أي تفسير منطقي لسبب رفضه للعملة، وهو ما يقلل من موثوقيته في القطاع المصرفي.

3.7.2 الدراسات المعتمدة على كشف الشذوذ وقابلية التفسير (Anomaly Detection & XAI)

اتجهت الأبحاث الأحدث نحو تبني نماذج كشف الشذوذ، حيث اقترح (Koo et al., 2024) نموذجاً يعتمد على المشفرات التلقائية (Autoencoders) لكشف المعاملات المالية المشبوهة، معتمدين على مبدأ بناء النموذج على البيانات السليمة فقط [1]. وفي سياق متصل بالعملات، قدم (Raut & Shakya, 2024) دراسة تعتمد على خوارزمية (Class SVDD One) لتصنيف العملات المزيفة باعتبارها فئة شاذة (Outliers) [7]. ولتعزيز الشفافية، برزت دراسة (Woldehana & Abebe, 2024) التي طبقت مبادئ الذكاء الاصطناعي القابل للتفسير (XAI) على العملة الإثيوبية لتوضيح أسباب التصنيف [2].

4.7.2 أوجه التميز ومساهمة المشروع الحالي (Systematic Comparison & Contribution)

عند تقاطع هذه الدراسات مع مشروعنا (SYP Shield AI)، تبرز القيمة العلمية والهندسية لهذا العمل من خلال معالجة الفجوات البحثية السابقة وتقديم الحلول التالية:

معالجة تحدي "البيئة غير المثالية": افترضت معظم الدراسات السابقة [4, 5] أن العملة المدخلة مقصودة وجاهزة للتحليل. يتميز نظامنا ببناء "خط تجميع بيانات" (Pipeline) مسبق وقوي يعتمد على خوارزمية (SIFT) وحساب مصفوفة التجانس (Homography) لعزل العملة آلياً وتصحيح ميلانها عن أي خلفية عشوائية، مما يجعله قابلاً للعمل الحقيقي عبر كاميرات هواتف المستخدمين.

الاستغناء عن البيانات المزورة: لتجاوز معضلة توفير بيانات التزوير، تبني المشروع معمارية (DeepCAE) المتقدمة ككاشف شذوذ (Anomaly Detector)، حيث يتم التدريب حصرياً على العملات السورية الحقيقية لتخفيض التكلفة الحسابية وزيادة دقة الأمان استناداً لخطأ إعادة البناء (RMSE).

التكامل المؤسسي والتفسير المرئي: لا يقف هذا المشروع عند حدود بناء الخوارزمية (كما في الأبحاث النظرية)، بل يدمج تقنية (Grad-CAM) لتقديم تفسير بصري فوري (Heatmaps). والأهم من ذلك، أنه يغلف هذه الخوارزميات داخل هندسة برمجيات متكاملة (عميل/خادم) باستخدام (Flutter) و (Django)، مع نظام إدارة صلاحيات (RBAC) يسمح للإداريين والخبراء بمراقبة وتقييم النظام، مما يجعله منتجاً برمجياً جاهزاً للنشر وليس مجرد نموذج اختباري.

الفصل الثالث

التطبيق العملي وتحليل النظام

1.3 تجميع وبناء مجموعة البيانات

يُعد توفر بيانات دقيقة وموثوقة حجر الأساس لنجاح أي نموذج تعلم عميق. نظراً لعدم توفر قاعدة بيانات عامة ومفتوحة المصدر للعملات السورية، تم تخصيص جهد بحثي وعملي كبير لبناء مجموعة بيانات (Dataset) محلية وموثوقة من الصفر. شملت عملية تجميع البيانات النقاط حوالي (700) صورة يدوياً باستخدام كاميرات هواتف ذكية حديثة، حيث تمت تغطية الفئات النقدية السورية المتداولة (10، 25، 50، 100، 200، 500 ليرة سورية) بوجهيها الأمامي والخلفي. ولضمان متانة النموذج (Robustness) وقدرته على التعميم (Generalization) في ظروف الاستخدام الحقيقي، تم مراعاة التنوع في بيئة التصوير، حيث التُقطت الصور تحت ظروف إضاءة مختلفة (طبيعية، صناعية، خافتة)، وعلى خلفيات متنوعة (طاوولات خشبية، أسطح قماشية، وممسوكة باليد)، وبزوايا ومسافات متفاوتة. لتحويل هذه البيانات الخام إلى بيئة قابلة للتدريب، تم تمرير جميع الصور عبر خوارزمية (SIFT) لقص العملة ومحاذاتها، مما أنتج "مجموعة بيانات نظيفة" (Clean Dataset) تحتوي حصراً على معالم الورقة النقدية بدقة (256x256) بيكسل، وهي البيانات التي تم الاعتماد عليها لتدريب واختبار شبكة (DeepCAE) لاحقاً.

2.3 تحليل النظام والمخططات الهندسية


لضمان بناء نظام برمجي متين وقابل للتطوير، تم اتباع منهجيات هندسة البرمجيات القياسية لتحليل المتطلبات وتوزيع الصلاحيات. يعتمد النظام في بنيته على هيكلية (العميل/الخادم) مدعومة بنظام إدارة صلاحيات متعدد المستويات (Role-Based Access Control).

1.2.3 مخطط حالات الاستخدام (Use Case Diagram)

يوضح الشكل (1-3) مخطط حالات الاستخدام التفاعل المباشر بين المستخدمين باختلاف أدوارهم والوظائف التي يتيحها النظام. تم تقسيم مستخدمي النظام إلى أربعة أدوار رئيسية:

1. الزائر (Guest): يمتلك صلاحيات محدودة جداً تسمح له بتجربة النظام وتقييم كفاءته من خلال فحص (صورتين فقط) يتم تتبعهما عبر معرف الجهاز، وبعدها يُلزم بإنشاء حساب.

2. **المستخدم المسجل (User):** بعد تسجيل الدخول، يُتاح له إجراء عدد غير محدود من الفحوصات اليومية للعمليات، بالإضافة إلى إمكانية استعراض أرشيف وسجل الفحوصات السابقة الخاصة به.
3. **الخبير (Expert):** يمتلك كافة صلاحيات المستخدم، بالإضافة إلى ميزات تحليلية متقدمة مثل قراءة الخرائط الحرارية (Heatmaps) بشكل مفصل، وصلاحيات "الإبلاغ عن إيجابية كاذبة" (False Positive Report) لإرسال العمليات المشكوك فيها إلى الخادم المركزي لتحسين النموذج مستقبلاً.
4. **مدير النظام (Admin):** يتحكم بالواجهة الخلفية، ويشرف على إدارة المستخدمين، ومراقبة إحصائيات النظام الشاملة.




الشكل (1-3): مخطط حالات الاستخدام للنظام.

2.2.3 مخطط البنية التحتية للنظام (System Architecture Diagram)

يوضح الشكل (2-3) الهيكلية الفنية لتدفق البيانات بين الطبقات الثلاث للنظام:

- **طبقة العرض (Frontend):** متمثلة بتطبيق (Flutter) الذي يوفر واجهة المستخدم.
- **طبقة الأعمال (Backend):** متمثلة بخادم (Django REST API) الذي يعالج الطلبات.


- **طبقة الذكاء الاصطناعي (AI Engine):** متمثلة ببيئة (PyTorch)، والتي تستلم الصورة الخام من الخادم، تمررها عبر وحدة (SIFT) للقص، ثم إلى (DeepCAE) لحساب الخطأ، وأخيراً إلى (Grad-CAM) لتوليد التفسير المرئي.



الشكل (3-2): مخطط البنية التحتية وتدفق البيانات.

3.2.3 مخطط قاعدة البيانات


لضمان حفظ سجلات المستخدمين ونتائج الفحص بكفاءة، تم تصميم قاعدة بيانات متماسكة واستخدام PostgreSQL [14] كنظام إدارة قاعدة المعطيات، و SQLite للتخزين المحلي. يوضح الشكل (3-3) الكيانات الأساسية للنظام، حيث يرتبط جدول (Users) بعلاقة مع جدول (Scan_Results) الذي يخزن الصورة الأصلية، الصورة المقصوفة، قيمة الخطأ، والخريطة الحرارية. كما تم إضافة كيان (False_Positive_Reports) المرتبط بالخبراء لإدارة وتخزين التغذية الراجعة.



الشكل (3-3): مخطط الكيانات والعلاقات لنموذج البيانات.

4.2.3 مخطط التتابع الشامل (System Sequence Diagram)


يوضح مسار تدفق العمليات زمنياً. تبدأ الدورة بالنقاط المستخدم للصورة عبر التطبيق وإرسالها كطلب إلى الخادم الذي يتحقق من الهوية. في حال كان زائراً وتجاوز الحد المسموح، يُرفض الطلب. وإلا تُمرر الصورة لمحرك الذكاء الاصطناعي للمعالجة، لتُحفظ النتيجة وتُعاد كاستجابة تُعرض على الشاشة.



الشكل (3-4): مخطط التتابع الشامل للنظام.

5.2.3 مخطط تدفق عمليات الذكاء الاصطناعي (AI Pipeline)


يُظهر مسار المعالجة الداخلي ضمن محرك الذكاء الاصطناعي. تبدأ العملية بمحاولة (SIFT) مطابقة وقص العملة. عند النجاح، تُمرر الصورة النظيفة للمشفّر التلقائي (DeepCAE) لحساب خطأ إعادة البناء (RMSE)، ثم تُستدعى (Grad-CAM) لبناء الخريطة الحرارية وإعادتها للخادم.



الشكل (3-5): مخطط تتابع محرك الذكاء الاصطناعي.

6.2.3 مخطط سير العمل العام (General System Workflow)


يبين مسارات اتخاذ القرار والمنطق البرمجي المتبع، حيث يُعالج النظام مسار الزوار وحساب الفحوصات التجريبية وتوجيههم للتسجيل، وصولاً إلى آلية الحفظ في أرشيف المستخدم لتوفير سجل مرجعي.



الشكل (3-6): مخطط سير العمل العام للنظام.

7.2.3 مخطط سير عمل المعالجة الذكية (AI Algorithm Workflow)

يمثل الخوارزمية المنطقية لعملية اتخاذ القرار. بعد حساب خطأ إعادة البناء (RMSE)، تمت برمجة شرط القرار النهائي عند العتبة (0.0540) المحددة تجريبياً. إذا كانت قيمة الخطأ أدنى أو تساوي هذه العتبة تُصنف العملة كحقيقية، وإلا تُعد مزورة.




الشكل (7-3): مخطط سير عمل الخوارزمية الذكية واتخاذ القرار.

8.2.3 مخطط الصفوف (Class Diagram)

يوضح الشكل (8-3) البنية الكائنية (Object-Oriented) للنظام والعلاقات المنطقية بين الكيانات البرمجية. يبرز المخطط فئات قاعدة البيانات الرئيسية في إطار (Django) مثل فئة (User) المربوطة

بعلاقة (One-to-Many) مع سجلات الفحص (ScanResult). كما يوضح المعمارية البرمجية لمحرك الذكاء الاصطناعي (AIEnginePipeline) الذي يعتمد على مبدأ التجميع (Composition) لاستدعاء وظائف خوارزمية (SIFTProcessor) والمشفر التلقائي (DeepCAEModel) لتنفيذ مهام المعالجة واستخراج النتائج.



الشكل (3-8): مخطط الصفوف (Class Diagram) للبنية الكائنية للنظام ومحرك الذكاء الاصطناعي.

3.3 واجهات التطبيق

تم تصميم وتطوير الواجهات الأمامية لتطبيق (SYP Shield AI) باستخدام إطار عمل (Flutter)، مع التركيز على مبادئ تجربة المستخدم (UX) وواجهة المستخدم (UI) الحديثة. تم اعتماد "الوضع المظلم"

(Dark Theme) كطابع أساسي للتطبيق ليعكس طابع الأمان والاحترافية التقنية، ولتوفير راحة بصرية للمستخدمين.

1.3.3 واجهات الترحيب والمصادقة (Onboarding & Authentication)

تمثل هذه الشاشات نقطة الاتصال الأولى بين المستخدم والنظام، وقد صُممت لتكون سلسلة، إرشادية، وآمنة.

أ. شاشة البداية والتمهيد الأمني (Splash Screen): تُمثل هذه الشاشة نقطة الاتصال الأولى فور

إطلاق التطبيق. تتضمن الشاشة رسالة تحميل تشير إلى تهيئة بيئة اتصال مشفرة مع الخادم

(Connection... Encrypting) قبل الانتقال إلى الواجهات الأساسية.




الشكل (3-9): شاشة البداية توضح الهوية البصرية والتمهيد الأمني للتطبيق.

ب. شاشات الترحيب والتعريف (Onboarding Screens): تظهر هذه الشاشات عند فتح التطبيق


للمرة الأولى، وتهدف إلى تثقيف المستخدم حول إمكانيات النظام بطريقة بصرية تفاعلية قبل بدء

الاستخدام. تتألف من ثلاث شاشات متتالية:


- الشاشة الأولى: تسلط الضوء على جوهر التطبيق المتمثل في الفحص المدعوم بالذكاء الاصطناعي (AI-Powered Banknote Verification).
- الشاشة الثانية: تبرز السرعة، الدقة، والأمان مع التنويه لاستخدام الذكاء الاصطناعي القابل للتفسير (Explainable AI).
- الشاشة الثالثة: تركز على الهدف النهائي وهو حماية تعاملات المستخدم المالية (Protect Transactions Your) مع زر للبدء الفعلي (Get Started).



(أ)



(ب)




(ج)


الشكل (3-10): شاشات الترحيب والتعريف بميزات النظام.

ج. شاشات المصادقة والدخول (Authentication Screens):

- شاشة إنشاء الحساب (Register): تتيح للمستخدم الجديد تسجيل بياناته (الاسم الكامل، البريد الإلكتروني، وكلمة المرور) لإنشاء حساب موثق يمنحه صلاحيات الفحص غير المحدود.
- شاشة تسجيل الدخول (Login): مخصصة للمستخدمين المسجلين للوصول إلى حساباتهم وسجل فحوصاتهم. وتتميز هذه الشاشة بوجود خيار جوهري وهو "الاستمرار كزائر (Continue as Guest)"، والذي يسمح للمستخدم بتجاوز خطوة التسجيل وتجربة التطبيق مباشرة وفق القيود الصارمة المحددة للزوار (فحص صورتين فقط).



(ب) تسجيل الدخول



(أ) إنشاء الحساب


الشكل (3-11): واجهات المصادقة وتسجيل الدخول مع خيار الزائر.

2.3.3 واجهات المستخدم الأساسية وعمليات الفحص (Core User Interfaces & Scanning)


تشكل هذه الواجهات جوهر النظام، حيث توفر للمستخدم المسجل بيئة عمل متكاملة لتنفيذ عمليات الفحص، استعراض النتائج، وإدارة حسابه بمرونة عالية.

أ. الشاشة الرئيسية وواجهة المسح الضوئي (Home & Scanner Screens):


- الشاشة الرئيسية (Home): توفر لوحة تحكم سريعة (Dashboard) تحتوي على زر بارز لبدء الفحص المباشر عبر الكاميرا (Start System Scan)، وخيار لرفع صورة من المعرض (Upload) للتحليل الفوري. كما تعرض شريط تنقل سفلي (Bottom Navigation Bar) للوصول السريع لباقي الأقسام.
- شاشة الكاميرا وإرشادات المسح (Scanner & Guidelines): لضمان جودة الصورة المدخلة (وهو أمر حاسم لنجاح خوارزمية SIFT في قص العملة)، تم تزويد واجهة الكاميرا بإطار توجيهي ذكي (Bounding Box). كما تم برمجة نافذة منبثقة (Modal) تظهر للمستخدم إرشادات الفحص السليم (وضع العملة على سطح مستوٍ، إضاءة جيدة، والمحاذاة داخل الإطار).



(ج)



(ب)



(أ)


الشكل (3-12): الشاشة الرئيسية وواجهة الكاميرا مع إرشادات المسح الضوئي.

ب. شاشات عرض نتائج الفحص (Scan Results Screens): تعتبر هذه الشاشات المخرج النهائي


لمحرك الذكاء الاصطناعي (DeepCAE)، حيث تُترجم القيم الرياضية المعقدة (RMSE) إلى واجهة بصرية واضحة ومباشرة للمستخدم العادي:

- **نتيجة العملة السليمة (Genuine):** تؤكد للمستخدم أن العملة اجتازت اختبار الأمان، مع عرض الصورة التي تم تحليلها، ورقم الفحص (Scan ID)، ونسبة ثقة الذكاء الاصطناعي (AI Confidence).

- **نتيجة العملة المزورة (Counterfeit):** توضح للمستخدم اكتشاف شذوذ (Security Anomaly) في البنية النسيجية للورقة النقدية وفشلها في اجتياز التحقق، مما يمنع وقوع المستخدم ضحية للاحتيال.



(ب)



(أ)

الشكل (3-13): شاشات عرض النتيجة النهائية للعملات الحقيقية والمزيفة.


ج. شاشات سجل الفحوصات (Scan History): تتيح هذه الواجهة للمستخدم تتبع نشاطاته السابقة، حيث تنقسم إلى تبويبات لتصفية النتائج (الكل All، الحقيقية Genuine، والمزورة Counterfeit). يعرض السجل تفاصيل كل عملية (التاريخ، الوقت، النتيجة، والصورة المصغرة)، مما يمنح المستخدم موثوقية وسجلاً مالياً وأمنياً يسهل الرجوع إليه.



(ج)



(ب)




(أ)


الشكل (3-14): واجهات السجل وتصفية الفحوصات السابقة.

د. واجهات الملف الشخصي والإعدادات (Profile & Settings):


- **الملف الشخصي (Profile):** تعرض بيانات المستخدم، وتتضمن ميزة إحصائية (Dashboards) توضح عدد الفحوصات الإجمالية، وعدد العملات السليمة والمزورة التي فحصها المستخدم.
- **تعديل البيانات (Edit Profile):** لتحديث المعلومات الشخصية وكلمة المرور بأمان.
- **الإعدادات (Settings):** تتضمن خيارات الوصول إلى مركز المساعدة، وخيار "إدارة الأجهزة" (Devices Management) والذي يُعد مهماً جداً تقنياً لتطبيق سياسة حظر الزوار الذين يتجاوزون الحد المسموح به من الفحوصات.



(ج)




(ب)



(أ)

الشكل (3-15): واجهات الملف الشخصي والإحصائيات وإعدادات النظام.

هـ. شاشة تفاصيل المشروع والشفافية التقنية (Project Details): انطلاقاً من مبدأ الشفافية، تم توفير واجهة مخصصة (تُستدعى من الإعدادات) لعرض المعلومات الهندسية للنظام. تقدم هذه الشاشة ملخصاً تنفيذياً (Executive Summary) يشرح للمستخدم آلية عمل النظام باختصار. كما تعرض بطاقات مرئية توضح حزمة التقنيات المستخدمة (Tech Stack)، مما يضيف طابعاً أكاديمياً واحترافياً على التطبيق.




الشكل (3-16): واجهة تفاصيل المشروع توضح الملخص التنفيذي وحزمة التقنيات المستخدمة.

3.3.3 واجهات الخبير والتحليل المتقدم (Expert Screens & Advanced Analysis)

صُممت هذه الواجهات خصيصاً للمستخدمين ذوي الصلاحيات المتقدمة (مثل موظفي البنوك أو المحققين الماليين). يوفر دور "الخبير" طبقة أمان إضافية للنظام تعتمد على مبدأ (Human-in-the-Loop)، حيث يساهم الخبير في تقييم أداء الذكاء الاصطناعي وتقديم تغذية راجعة (Feedback) لتحسين النموذج مستقبلاً.

أ. الشاشة الرئيسية والملف الشخصي للخبير (Expert Home & Profile): تتشابه هذه الشاشات هيكلياً مع واجهات المستخدم العادي، ولكنها تتميز بإبراز شارة (Expert Badge) لتأكيد مستوى الصلاحيات.

بالإضافة إلى ذلك، توفر لوحة التحكم الرئيسية للخبير وصولاً سريعاً لأدوات متقدمة غير متاحة للمستخدم العادي، مثل قسم إدارة التقارير ومراقبة نشاطات النظام.



(ب)




(أ)


الشكل (3-17): الشاشة الرئيسية والملف الشخصي المخصص لدور الخبير.

ب. شاشة النتائج المتقدمة والخرائط الحرارية (Advanced Results & Heatmaps): تختلف شاشة النتيجة الخاصة بالخبير جوهرياً عن المستخدم العادي، حيث تم دمج مبادئ الذكاء الاصطناعي القابل للتفسير (XAI) بداخلها:

- عرض الخريطة الحرارية (Grad-CAM): يتم تراكب خريطة حرارية دقيقة فوق صورة العملة لتحديد "النقاط الساخنة" (Hotspots) التي أدت إلى ارتفاع خطأ إعادة البناء (RMSE).
- خيارات التوثيق والإبلاغ: تتضمن الشاشة أزراراً إضافية تتيح للخبير تحميل النتيجة كوثيقة رسمية، أو زر الإبلاغ عن خطأ في حال اشتباه الخبير بوجود إيجابية كاذبة (False Positive).



(ب)




(أ)

الشكل (3-18): واجهات الفحص للخبير تبرز الخرائط الحرارية وأزرار التوثيق والإبلاغ.

ج. واجهات الإبلاغ وفحوصات المجتمع (Reporting & Community Scans): تطبيقاً لمخطط

قاعدة البيانات، يمتلك الخبير أدوات فعالة لإدارة جودة النظام:

- واجهة الإبلاغ عن خطأ (Report Error): عبارة عن نموذج (Form) يتيح للخبير كتابة ملاحظاته الفنية حول عملة معينة صنفها النظام بشكل خاطئ، وإرسالها مباشرة للخادم ليتم مراجعتها.
- سجل تقاريري (My Reports): واجهة مخصصة لتتبع حالة التقارير التي أرسلها الخبير مسبقاً (قيد الانتظار Pending، أو تمت المراجعة).
- فحوصات المجتمع (Community Scans): تتيح للخبير استعراض الفحوصات التي أجراها المستخدمون، مما يساعد في اكتشاف أنماط التزوير الجديدة المنتشرة في السوق بسرعة.



(ج)

(ب)


(أ)

الشكل (3-19): واجهات الإبلاغ عن الأخطاء، تتبع التقارير، ومراقبة فحوصات المجتمع.


4.3.3 واجهات الزائر والقيود البرمجية (Guest Screens & Access Limitations)

تُجسد هذه الواجهات التطبيق العملي للقيود الأمنية المفروضة على دور "الزائر" (Guest) كما تم توضيحها في مخططات سير العمل. الهدف من هذا الدور هو منح المستخدم تجربة سريعة ومباشرة لكفاءة النظام في الفحص، مع حثه برمجياً على إنشاء حساب.

- الشاشة الرئيسية للزائر (Guest Home): تتيح للزائر إجراء الفحص المباشر للعملة، بينما يقوم الخادم بالخلفية بتتبع معرف الجهاز لتطبيق سياسة الاستخدام المحدود (صورتين فقط كحد أقصى).
- واجهات التقييد (Restricted Access): عند محاولة الزائر الوصول إلى ميزات مخصصة للمستخدمين المسجلين، مثل "سجل الفحوصات" (Scan History) أو "الملف الشخصي" (Profile)، يتدخل النظام برمجياً لمنع الوصول، ويعرض بدلاً من ذلك واجهة إرشادية تطالب المستخدم بتسجيل الدخول أو إنشاء حساب جديد للاستفادة الكاملة من كافة ميزات النظام.



(ب)



(أ)


الشكل (3-20): الشاشة الرئيسية للزائر والقيود البرمجية المفروضة على السجل.

5.3.3 واجهات مدير النظام ولوحة التحكم المركزية (Admin Dashboard & Control Panel)

على عكس بقية المستخدمين الذين يقتصر تفاعلهم على تطبيق الهاتف المحمول، يتمتع "مدير النظام" (Admin) ببيئة عمل ويب متكاملة (Web-based Dashboard) مرتبطة مباشرة بالواجهة الخلفية (Django Backend). صُممت هذه اللوحة لتوفير تحكم مركزي، مراقبة شاملة، وإدارة دقيقة لكافة موارد النظام برمجياً وأمنياً.


أ. لوحة المعلومات الرئيسية (System Overview): توفر هذه الواجهة نظرة لحالة النظام لحظياً. تعرض إحصائيات حية حول إجمالي الفحوصات على مستوى الشبكة، عدد حالات التزوير

المكتشفة، التقارير المعلقة، وعدد المستخدمين النشطين، بالإضافة إلى مؤشر لضمان عمل نماذج الذكاء الاصطناعي (DeepCAE Models) ومراقبتها للشبكة بكفاءة.



الشكل (3-21): لوحة المعلومات الرئيسية لحالة النظام.


ب. دليل مستخدمي النظام (System Users Directory): واجهة مخصصة لإدارة هويات المستخدمين والتحقق من نشاطهم. تتيح للمدير تعيين أو تعديل الصلاحيات الأمنية للمستخدمين (User Admin, Expert)، مع عرض إحصائية سريعة توضح حجم التفاعل وعدد الفحوصات الخاصة بكل مستخدم نشط.



الشكل (3-22): واجهة إدارة هويات مستخدمي النظام وصلاحياتهم.

ج. سجل الفحوصات الشامل (System Scan Ledger):


تمثل هذه الواجهة أداة التدقيق الأمني (Audit) الأساسية للمدير. تتألف من جدول بيانات مركزي يوثق جميع عمليات الفحص التي تمت عبر الشبكة. تعرض تفاصيل حاسمة ودقيقة مثل (قيمة خطأ إعادة البناء MSE، نسبة الثقة، والقرار النهائي)، مما يضمن شفافية تامة لكافة العمليات المنفذة في النظام وتتبعها زمنياً.



SCAN ID & DATE	METRICS	VERDICT	ACTION
SCN-31 2026-05-31	MSE: 0.064 70.4% CONF	COUNTERFEIT	View Details
SCN-30 2026-05-31	MSE: 0.062 70.3% CONF	GENUINE	View Details
SCN-29 2026-05-30	MSE: 0.058 72.6% CONF	GENUINE	View Details
SCN-28 2026-05-30	MSE: 0.056 73.5% CONF	GENUINE	View Details
SCN-27 2026-05-30	MSE: 0.059 72.0% CONF	GENUINE	View Details
SCN-26 2026-05-30	MSE: 0.070 73.2% CONF	COUNTERFEIT	View Details
SCN-25	MSE: 0.068		


الشكل (3-23): السجل الشامل لعمليات الفحص على مستوى الشبكة.

د. تقارير الخبراء والشذوذ (Expert Feedback & Anomaly Reports): واجهة مخصصة لاستقبال ومراجعة التقارير المرفوعة من "الخبراء" (Experts) حول حالات الإيجابية الكاذبة (False Positives) أو العملات المشكوك فيها. يمكن للمدير من خلالها تتبع حالة التقارير (قيد الانتظار Pending، أو تمت المراجعة) لاتخاذ قرارات تقنية فورية كإصدار تحديثات للنموذج (Deploy Patch).




الشكل (3-24): واجهة استقبال التغذية الراجعة وتقارير الخبراء.

هـ. سياسات الأدوار والتطبيق (Role & App Policies): تجسد هذه الواجهة التطبيق العملي الفعال لمبدأ التحكم بالوصول المبني على الأدوار (RBAC). تنتج للمدير تحكماً ديناميكياً بصلاحيات كل دور (User, Guest Expert). يمكن من خلالها برمجة وتعديل "الحد اليومي للفحوصات" (Daily Scan Limit)، و"أيام الاحتفاظ بالسجل"، وتفعيل أو تعطيل ميزات حساسة مثل (رؤية الخريطة الحرارية، وقيمة الـ MSE، وتصدير التقارير).



الشكل (3-25): واجهة التحكم الديناميكي بسياسات الصلاحيات.

و. إعدادات المنصة (Platform Settings): تُعنى هذه الشاشة بالتحكم بالتكوين العالمي للنظام ككل. توفر خيارات أمنية وإدارية متقدمة، مثل أتمتة النسخ الاحتياطي لقواعد البيانات، وتفعيل "وضع الصيانة" (Maintenance Mode) لإيقاف وصول المستخدمين مؤقتاً أثناء عمليات الترقية والتحديث.



الشكل (3-26): واجهة التحكم بإعدادات المنصة المتقدمة.

4.3 أمن النظام وحماية البيانات

نظراً لطبيعة التطبيق الحساسة لارتباطه بالمجال المالي والمصرفي، تم تصميم معمارية النظام وفق مبدأ "الأمن أولاً" (Security-by-Design). تم تطبيق طبقات متعددة من الحماية على مستوى الخادم (Server)، وقاعدة البيانات (Database)، وواجهات برمجة التطبيقات (APIs) لضمان وثوقية النظام وخصوصية المستخدمين.

1.4.3 أمن واجهات برمجة التطبيقات (API Security & Authentication)

بما أن النظام يعتمد على معمارية (عميل/خادم) منفصلة، فإن تأمين الاتصال بين تطبيق (Flutter) وخادم (Django) يُعد أمراً بالغ الأهمية. لتحقيق ذلك، تم الابتعاد عن الجلسات التقليدية (Sessions) والاعتماد على بروتوكول (JSON Web Tokens - JWT). عند تسجيل دخول المستخدم بنجاح، يقوم الخادم بإصدار رمز وصول (Access Token) مشفر يحمل توقيعاً رقمياً، ويتم استخدامه في ترويسة (Header) كل طلب (HTTP Request) لاحق. تضمن هذه الآلية:

- الاستغناء عن تخزين حالة المستخدم في الخادم (Stateless Authentication).
- منع هجمات تزوير الطلبات عبر المواقع (CSRF).
- انتهاء صلاحية الجلسات تلقائياً (Token Expiration) في حال سرقة الرمز، مما يتطلب من المستخدم إعادة المصادقة باستخدام (Refresh Token).

2.4.3 التحكم بالوصول ومكافحة الإغراق (RBAC & Rate Limiting)

لمنع استنزاف موارد خادم الذكاء الاصطناعي (GPU/CPU) عبر هجمات الحرمان من الخدمة (DDoS) أو الاستخدام العشوائي، تم توظيف نظام (Role-Based Access Control) مدعوم بقيود زمنية (Limiting Rate) صارم:

- تتبع الأجهزة (Device Fingerprinting): يتم تتبع حسابات الزوار غير المسجلين عبر المعرف الفريد للجهاز (Device ID) وعنوان (IP)، وتقييد صلاحياتهم بفحصين فقط كحد أقصى، ليُجبر النظام المستخدم بعدها على إنشاء حساب رسمي لردع الاستخدام التخريبي.
- الحد اليومي للفحوصات (Daily Quotas): ترتبط كل صلاحية (مستخدم، خبير) بحد أعلى يومي لعدد الصور المسموح برفعها إلى السيرفر، وتتم إدارة هذه القيود ديناميكياً من لوحة تحكم المدير.

3.4.3 خصوصية البيانات ومعالجة الصور المتطايرة (Volatile Image Processing)

من أهم التحديات القانونية والأخلاقية في تطبيقات الذكاء الاصطناعي هو كيفية التعامل مع بيانات المستخدمين. في هذا النظام، تم تبني سياسة "المعالجة المتطايرة" (Volatile Processing) لصور العملات التي يرفعها المستخدمون:

- لا يتم تخزين الصور المرسلة للفحص بشكل دائم في قاعدة البيانات أو على أقراص الخادم السحابي.
- يتم استقبال الصورة، معالجتها في الذاكرة العشوائية (RAM) عبر خوارزميات (SIFT) و (DeepCAE)، واستخراج الخريطة الحرارية (Grad-CAM)، ثم تُحذف الصورة الأصلية.
- يُخزن في قاعدة البيانات فقط "سجل الفحص" (Audit Log) الذي يضم (معرف المستخدم، التاريخ، قيمة خطأ RMSE، والقرار النهائي) لأغراض الإحصاء والمراقبة، مما يضمن خصوصية تامة للمستخدم ويقلل من تكاليف التخزين السحابي (Storage Costs).

الفصل الرابع النتائج والاختبارات

1.4 مقدمة

يستعرض هذا الفصل النتائج العملية التي حققها النظام بعد تحويل التصميمات الهندسية والخوارزميات النظرية إلى بيئة تطبيقية ملموسة. يتم تقييم أداء النظام عبر استعراض بيئة التدريب، كفاءة خوارزمية المعالجة المسبقة في التعامل مع الصور العشوائية، تتبع مراحل تطور نموذج الذكاء الاصطناعي، وأخيراً تحليل النتائج الإحصائية الدقيقة لنموذج (DeepCAE) ومخرجات قابلية التفسير المرئي (Grad-CAM).

2.4 بيئة الاختبار والتدريب (Training & Testing Environment)


نظراً للحجم الكبير للبيانات والحاجة إلى قدرات حوسبة عالية لتدريب شبكات التعلم العميق، تم تنفيذ وبناء محرك الذكاء الاصطناعي في بيئة سحابية متطورة. تم الاعتماد على منصة (Kaggle) لتوفير بيئة (Notebook) تفاعلية مدعومة بمسرعات رسومات مزدوجة من نوع (NVIDIA Tesla T4 GPUs x2) لضمان تسريع عمليات حساب المصفوفات (Tensors) وتقليل زمن التدريب. تمت كتابة الأكواد بلغة (Python)، بالاعتماد على حزمة (PyTorch) كأطار عمل أساسي لبناء معمارية (DeepCAE)، ومكتبة (OpenCV) لتنفيذ المعالجة المسبقة (SIFT)، ومكتبتي (Pandas) و (Matplotlib) لتحليل البيانات ورسم المنحنيات الإحصائية.



3.4 اختبارات المعالجة المسبقة والمحاذاة

تُعد جودة الصورة المدخلة العامل الأكثر حسماً في نجاح نماذج كشف الشذوذ (Anomaly Detection). في سيناريوهات الاستخدام الحقيقي، يقوم المستخدمون بالنقاط صور للعملات بظروف غير مثالية (إضاءة متفاوتة، زوايا النقاط مائلة، خلفيات مشتتة، أو الإمساك بالعملة باليد).

لاختبار متانة النظام (Robustness) في التعامل مع هذه التحديات، تم تمرير مجموعة من الصور المعقدة الملتقطة عبر كاميرا الهاتف الذكي إلى وحدة المعالجة المسبقة المعتمدة على خوارزمية (SIFT). تُظهر النتائج العملية كفاءة عالية للخوارزمية في:

1. استخراج الميزات (Feature Extraction): القدرة على اكتشاف النقاط المرجعية للعملة وتجاهل الضجيج الخلفي (مثل لوحة المفاتيح أو الطاولة).
2. المطابقة (Feature Matching): ربط النقاط المستخرجة بخريطة العملة الأصلية (كما توضح الخطوط الخضراء في نتائج الاختبار).
3. التسوية الهندسية (Homography & Alignment): حساب مصفوفة التجانس لتصحيح زاوية الميلان (Perspective Distortion)، وقص العملة حصراً، وإعادة تحجيمها إلى أبعاد قياسية وثابتة (256x256) بيكسل، لتكون جاهزة للإدخال إلى شبكة (DeepCAE) خالية من أي عوامل مشتتة.





الشكل (1-4): أمثلة عملية لاختبارات SIFT توضح نجاح الخوارزمية في استخراج الميزات، تصحيح الميلان، وقص العملات المأخوذة في ظروف عشوائية.

4.4 مراحل تطور النموذج والمقارنة

لم يتم الوصول إلى النموذج النهائي بخطوة واحدة، بل مر النظام بعدة مراحل من التجربة والتطوير (and Error Trial) لتحسين قدرة الشبكة العصبية على استخلاص أدق الميزات النسيجية للعملة السورية. تم توثيق هذه التجارب في سجل الأداء (Experiments Log) ومقارنة النتائج بناءً على معمارية الشبكة، أبعاد الصورة، وتركيب دالة الخسارة (Loss Function).

جدول (1-4): مقارنة مراحل تطور نموذج كشف الشذوذ

المرحلة	النموذج (Model)	أبعاد الدخل	Epochs	دالة الخسارة	الخسارة
النموذج الأولي	Simple CAE	128×128	10	MSE	0.00192
النموذج المتوسط	DeepCAE	256×256	20	MSE+SSIM	0.15871
النموذج النهائي	DeepCAE+Clean Data	256×256	50	RMSE+SSIM	0.16671

1.4.4 النموذج الأولي (Simple CAE)

أظهر خسارة رياضية منخفضة جداً (0.00192)، لكنها كانت "خسارة مضللة" بسبب صغر حجم الصورة (128×128) وبساطة المعمارية، حيث فشل النموذج في التقاط التفاصيل الأمنية والزخارف الدقيقة للعملة واكتفى بتعلم الألوان العامة.

2.4.4 النموذج المتوسط (DeepCAE)

لمعالجة قصور النموذج الأول، تم زيادة عمق الشبكة وأبعاد الصورة إلى (256×256)، مع دمج مؤشر التشابه البنيوي (SSIM) مع دالة (MSE) لإجبار الشبكة على التركيز على الهيكل. تحسن الأداء بشكل ملحوظ، لكنه عانى من عدم استقرار في التدريب بسبب محاولة الشبكة حفظ الخلفيات العشوائية المرافقة لصور العملات.

3.4.4 النموذج النهائي (DeepCAE + Clean Data)

وهو النموذج المعتمد في التطبيق. تم تدريبه حصرياً على البيانات بعد قصها وتنقيتها بالكامل عبر خوارزمية (SIFT). ولزيادة صرامة التقييم، استُخدمت دالة خسارة (RMSE + SSIM) التي تعاقب الأخطاء الكبيرة بشكل مضاعف. أظهر هذا النموذج استقراراً عالياً (على مدار 50 حقبة) وقدرة ممتازة على إعادة بناء معالم العملة بدقة، مما سمح لنا لاحقاً بتحديد عتبة قرار دقيقة جداً للفصل بين الحقيقي والمزور.


5.4 تحليل مسار التطوير

1. أبعاد الإدخال: أثبتت التجارب الأولى أن دقة (128x128) غير كافية لتحليل الخزاف الدقيقة في العملة، لذلك تم الانتقال إلى دقة (256x256) التي قدمت توازناً مثالياً بين وضوح التفاصيل (Resolution) والتكلفة الحسابية.
2. تطور دالة الخسارة (Loss Function): بدأنا باستخدام الخطأ التربيعي المتوسط (MSE) التقليدي، لكنه كان يعطي وزناً متساوياً لجميع البكسلات. لتعزيز قدرة النموذج على الانتباه لـ "هيكل العملة"، تم دمج مؤشر التشابه البنيوي (SSIM). وفي المرحلة النهائية، استُخدم (RMSE) كونه يعاقب الأخطاء الكبيرة بشكل أكثر صرامة، مما ساعد في إيجاد عتبة قرار (Threshold) دقيقة جداً للفصل بين الحقيقي والمزور.
3. أهمية البيانات النظيفة (Clean Data): يظهر السجل أن استقرار (النموذج النهائي) لم يكن فقط بسبب زيادة الحقب (50 Epochs)، بل بسبب استخدام مجموعة البيانات النظيفة (المعالجة عبر SIFT)، مما منع الشبكة من تشتت أوزانها (Weights) في محاولة إعادة بناء الخلفيات العشوائية.

6.4 تقييم أداء النموذج النهائي (Model Evaluation)

بعد الاستقرار على معمارية (DeepCAE) المدمجة بالبيانات المنقاة (Clean Data)، تم تدريب النموذج لمدة 50 حقبة (Epochs). لتقييم كفاءة النظام بشكل علمي دقيق، تم اختباره على مجموعة بيانات اختبار (Set Test) مكونة من 120 صورة (60 عملة حقيقية، و60 عملة مزورة محاكية اصطناعياً).

أ. تحليل منحنيات التدريب (Training & Validation Curves): يوضح الشكل (2-4) منحنيات التعلم للنموذج. يُلاحظ من منحنى الخسارة (Loss Curve) هبوط متزامن وسلس لكل من خسارة التدريب (Train Loss) وخسارة التحقق (Val. Loss)، مما يثبت أن النموذج يتعلم بشكل صحيح دون الوقوع في مشكلة الإفراط في الملاءمة (Overfitting). وفي المقابل، يُظهر منحنى دقة التحقق (Validation Accuracy) تصاعداً تدريجياً واستقراراً في المراحل الأخيرة حول نسبة 85% إلى 88%.



الشكل (2-4): منحنيات الخسارة ودقة التحقق خلال 50 حقبة تدريبية.


ب. مصفوفة الارتباك والمقاييس الإحصائية (Confusion Matrix & Metrics): تُعد مصفوفة الارتباك المعيار الذهبي لتقييم الأنظمة الأمنية. بناءً على الاختبارات، استقر النظام عند عتبة قرار (Threshold) رياضية صارمة بلغت (0.06907) لخطأ إعادة البناء.

أسفرت هذه العتبة عن النتائج التالية الموضحة في مصفوفة الارتباك:

- الدقة الإجمالية (Accuracy): بلغت 88.33%، وهي نسبة ممتازة تعكس قدرة النظام العامة على التصنيف الصحيح.
- الضبط (Precision): حقق النظام نسبة 100%، حيث يوضح المربع الأعلى الأيمن في المصفوفة (0) أن النظام لم يسمح بمرور أي عملة مزورة على أنها حقيقية (Zero False Positives for).

(Genuine). في الأنظمة المالية، يعتبر هذا المؤشر حاسماً لأن تمرير عملة مزورة يشكل خطراً أمنياً يفوق رفض عملة حقيقية.

- **الاستدعاء (Recall):** بلغت النسبة 76.67% . يشير المربع الأسفل الأيسر (14) إلى أن النظام قام برفض 14 عملة حقيقية واعتبرها مزورة. يعود هذا إلى العتبة الصارمة جداً للنظام (Security-First Approach)، فالنظام يفضل رفض عملة حقيقية متضررة جداً أو مهترئة (لتحذير المستخدم) على أن يغامر بقبول عملة مشكوك فيها.



الشكل (4-3): مصفوفة الارتباك (Confusion Matrix).

7.4 اختبارات قابلية التفسير (Grad-CAM Visual Explanations)


لتجاوز معضلة "الصندوق الأسود" (Black Box) في نماذج التعلم العميق، وزيادة موثوقية النظام لدى المستخدمين العاديين والخبراء، تم توظيف خوارزمية (Grad-CAM) لتوليد تفسيرات بصرية (Visual Explanations) لقرارات النموذج بناءً على قيم خطأ إعادة البناء (RMSE).

يوضح الشكل (4-4) اختبارين لعملات سورية من فئة (500 ل.س) و (50 ل.س) بوجهيها الحقيقي والمزور:


1. **العملات الحقيقية (الصفوف العلوية):** استطاع المشفر التلقائي (Autoencoder) إعادة بناء تفاصيل العملة بكفاءة عالية، مما أدى إلى خطأ منخفض (Low RMSE). تظهر الخريطة الحرارية بألوان باردة (أزرق داكن) مع غياب شبه تام للبقع الساخنة، مما يؤكد خلو العملة من الشذوذ.
2. **العملات المزورة (الصفوف السفلية):** عند إدخال صور مزورة تحتوي على تشوهات نسيجية أو ضجيج طباعي لم يتدرب عليه النموذج، ارتفعت قيمة الخطأ الرياضي. تترجم خوارزمية Grad-CAM هذا الفشل في إعادة البناء إلى "بقع ساخنة" (ألوان حمراء وصفراء) تتمركز بدقة فوق الأماكن التي اكتشف الذكاء الاصطناعي فيها تلاعباً (مثل غياب الدقة في الزخارف أو اختلاف العلامات المميزة في العملة).

هذه الخرائط المرئية لا تثبت فقط دقة الخوارزمية، بل توفر للجهات المصرفية والخبراء أداة تدقيق بصري قاطعة.

(أ): فئة 500 ليرة سورية جديدة



(ب): فئة 50 ليرة سورية جديدة



الشكل (4-4): التفسير البصري للذكاء الاصطناعي (Grad-CAM).

الفصل الخامس

الخاتمة والتوصيات المستقبلية

1.5 التحديات التي واجهت المشروع

خلال مراحل البحث والتطوير لبناء هذا النظام المتكامل، واجهنا مجموعة من التحديات الهندسية والبرمجية التي تطلبت حلولاً منهجية مبتكرة:

- **ندرة البيانات الموثوقة (Data Scarcity):** لعل التحدي الأكبر كان عدم توفر قاعدة بيانات عامة (Dataset) للعملاء السورية، وندرة الحصول على عينات مزورة حقيقية لتدريب الذكاء الاصطناعي. تم التغلب على هذا التحدي برمجياً عبر تغيير استراتيجية التعلم من (التصنيف الثنائي) إلى (كشف الشذوذ - Detection Anomaly)، وتدريب النظام حصرياً على العملات الحقيقية، مع استخدام تقنيات محاكاة التزوير الاصطناعي (Data Augmentation) لتقييم النموذج.
- **الضجيج والخلفيات العشوائية في الصور:** نظراً لأن النظام سيعمل عبر كاميرات هواتف المستخدمين في بيئات حقيقية، كانت الصور المدخلة مليئة بالخلفيات المشتتة والزوايا المائلة التي تؤثر على دقة الذكاء الاصطناعي. تم حل هذه المعضلة بنجاح عبر بناء وحدة معالجة مسبقة صارمة تعتمد على خوارزمية (SIFT) لقص العملة ومحاذاتها هندسياً قبل تمريرها للشبكة العصبية.
- **الموازنة بين الأمان وتجربة المستخدم:** شكل فرض قيود أمنية صارمة على عمليات الفحص (لمنع إساءة الاستخدام) تحدياً في الحفاظ على سلاسة واجهة المستخدم. تم تجاوز ذلك عبر بناء معمارية خادم قوية باستخدام (Django) تدير الصلاحيات (RBAC) بكفاءة، وواجهات أمامية بـ (Flutter) تقدم تغذية راجعة فورية ومريحة للمستخدم.

2.5 الآفاق والتوصيات المستقبلية

يضع هذا المشروع حجر الأساس لنظام أمني مالي قابل للتوسع. ولتطوير النظام مستقبلاً، نوصي بالمسارات التالية:

1. **دعم فئات نقدية أجنبية متطورة:** توسيع قدرات النموذج لتدريبه على فئات نقدية دولية (كالدولار الأمريكي أو اليورو)، مما يفتح المجال لتسويق التطبيق للمصارف وشركات الصرافة الإقليمية.

2. **الذكاء الاصطناعي الطرفي (Edge AI):** نقل نموذج التعلم العميق (DeepCAE) ليعمل محلياً على معالج الهاتف المحمول بدلاً من السيرفر المركزي. هذا التطوير سيقبل من زمن الاستجابة (Latency) ويسمح باستخدام التطبيق في وضع عدم الاتصال بالإنترنت.
3. **التكامل مع الأجهزة العتادية (Hardware Integration):** بناء واجهة برمجة تطبيقات (API) إضافية تسمح بدمج محرك الذكاء الاصطناعي الخاص بالنظام مع آلات عد النقود والماسحات الضوئية البنكية لتوفير طبقة فحص مزدوجة في المصارف.
4. **تطوير خوارزميات كشف الشذوذ:** دمج تقنيات شبكات التوليد التنافسية (GANs) في تدريب النظام لتوليد عينات مزورة أكثر تعقيداً هندسياً، مما يزيد من مناعة النموذج ضد عمليات التزييف فائقة الدقة.

3.5 الخاتمة

قدم هذا المشروع حلاً تقنياً متكاملًا لمواجهة واحدة من أعقد المشاكل التي تهدد الاقتصادات المحلية، ألا وهي تزوير الأوراق النقدية. من خلال دمج تقنيات الرؤية الحاسوبية والتعلم العميق، تم بناء نظام (عميل/خادم) قوي يتيح للمواطنين العاديين والخبراء الماليين أداة تحقق فورية وموثوقة عبر هواتفهم الذكية. أثبتت النتائج التجريبية كفاءة استثنائية لمعمارية المشفر التلقائي التلافيفي العميق (DeepCAE) في اصطياد الشذوذ النسيجي في العملات، مدعومة بخوارزمية (SIFT) للمعالجة المسبقة. والجدير بالذكر أن النظام حقق دقة استدعاء وضبط عالية، ولم يسمح بتمرير أي عملة مزورة في بيانات الاختبار، مما يثبت موثوقيته الأمنية العالية. إضافة إلى ذلك، نقلت خوارزمية (Grad-CAM) المشروع من مجرد نظام تصنيف أعمى إلى "ذكاء اصطناعي قابل للتفسير" يبرر قراراته بصرياً، مما يعزز ثقة المؤسسات المالية في مخرجاته. نأمل أن يمثل تطبيق (SYP Shield AI) مساهمة علمية وعملية جادة في مجال أمن المعلومات والاقتصاد، وأن يكون نواة لأنظمة حماية وطنية أكثر تطوراً.

قائمة المصطلحات والاختصارات

Abbreviation	Full Meaning
AI	Artificial Intelligence
API	Application Programming Interface
CNN	Convolutional Neural Network
CSRF	Cross-Site Request Forgery
DDoS	Distributed Denial of Service
DeepCAE	Deep Convolutional Autoencoder
DoG	Difference of Gaussian
DRF	Django REST Framework
FN	False Negative
FP	False Positive
GANs	Generative Adversarial Networks
Grad-CAM	Gradient-weighted Class Activation Mapping
IP	Internet Protocol
JWT	JSON Web Token
ML	Machine Learning
MSE	Mean Squared Error
ORM	Object-Relational Mapping
PBKDF2	Password-Based Key Derivation Function 2
RAM	Random Access Memory
RBAC	Role-Based Access Control
ReLU	Rectified Linear Unit
RMSE	Root Mean Squared Error
SHA-256	Secure Hash Algorithm 256-bit
SIFT	Scale-Invariant Feature Transform
SQL	Structured Query Language
SSIM	Structural Similarity Index Measure
SVDD	Support Vector Data Description
TN	True Negative
TP	True Positive
UI / UX	User Interface / User Experience
XAI	Explainable Artificial Intelligence

References المراجع

- [1] Koo, K., Park, M., and Yoon, B. (2024) **A Suspicious Financial Transaction Detection Model Using Autoencoder and Risk-Based Approach**, IEEE Access, vol. 12.
- [2] Woldehana, Y. D. and Abebe, M. (2024) **An Explainable Counterfeit and Genuine Ethiopian Banknote Classification using Deep Learning**, SSRN Electronic Journal.
- [3] Ali, T., Jan, S., Alkhodre, A., Nauman, M., Amin, M., and Siddiqui, M. S. (2019) **DeepMoney: counterfeit money detection using generative adversarial networks**, PeerJ Computer Science.
- [4] Hamed, N. M. Z. and Al Azzo, F. (2024) **Develop a Robust System for Detecting Counterfeit Iraq Currencies Based on Deep Learning Techniques**, Journal of Computational Analysis and Applications, vol. 33, no. 2.
- [5] Gebremeskel, G., Tadele, T. A., Girmaw, D. W., and Salau, A. O. (2022) **Developing a Model for Detection of Ethiopian Fake Banknote Using Deep Learning**, Research Square.
- [6] Dittimi, T. V. (2019) **Banknote Authentication and Medical Image Diagnosis Using Feature Descriptors and Deep Learning Methods**, PhD Thesis, Montreal: Concordia University.
- [7] Raut, R. and Shakya, A. (2024) **One-Class Counterfeit Currency Classification Using Deep Support Vector Data Description (SVDD)**, Kathmandu University.
- [8] Lowe, D. G. (2004) *Distinctive Image Features from Scale-Invariant Keypoints*, International Journal of Computer Vision, vol. 60, pp. 91-110.
- [9] Paszke, A., Gross, S., Massa, F., Lerer, A., and Bradbury, J. (2019) *PyTorch: An Imperative Style, High-Performance Deep Learning Library*, Advances in Neural Information Processing Systems, vol. 32, pp. 8024-8035.
- [10] Tian, X. (2024). **A Deep Convolutional Autoencoder–Enabled Channel Estimation Method in Intelligent Wireless Communication Systems**. International Journal of Intelligent Systems, 2024(1), 9343734.
- [11] <https://flutter.dev> (accessed 04/06/2026).
- [12] <https://www.djangoproject.com> (accessed 04/06/2026).
- [13] <https://www.django-rest-framework.org> (accessed 04/06/2026).
- [14] <https://www.postgresql.org> (accessed 04/06/2026).
- [15] [syrian-currency-real-dataset](#) (accessed 04/6/2026).

Abstract

The phenomenon of banknote counterfeiting poses a persistent threat to economic and security stability. With the development of digital printing technologies, the urgent need has arisen for the development of intelligent, user-friendly, and accessible verification systems for both ordinary users and experts. This project aims to build an integrated software system (client/server) embodied in a mobile application dedicated to the intelligent detection of counterfeit Syrian currency denominations.

The work plan relies on data processing in two main phases. The first phase involves software engineering and purification of the data, where an automatic alignment and clipping unit was built based on the Invariant Feature Transform with Scale (SIFT) algorithm and homography matrix calculation to ensure the isolation of banknotes from random backgrounds and the accurate and consistent uniformity of their dimensions. The second phase involves inference and comprehensive learning, where a deep neural network of the DeepCAE type was developed, enhanced with batch norm and dropout calibration layers to avoid overfitting. The model was trained as an anomaly detector on the structural and microtextural features of genuine banknotes only, calculating the reconstruction error as a sorting and classification criterion. To achieve the interpretability principle of artificial intelligence (XAI), the Grad-CAM algorithm was integrated to generate visual heat maps that accurately show the user the high-frequency anomaly locations that led to the banknote being classified as counterfeit.

The experimental results demonstrated high efficiency and stability in the learning and validation curves, with the system stabilizing at a strict final classification threshold of 0.06907 (root mean square error). This threshold proved to be highly effective at detecting counterfeits with extreme accuracy and separating high-frequency distortions and defects in counterfeit banknotes and scanned cards, while providing excellent visual interpretations. The system's software architecture was built with complete integration, where the front-ends for the mobile application were developed using the Flutter framework, while the back-end server for managing operations and artificial intelligence was built using the Django REST Framework in Python, ensuring flexible software distribution and advanced security permissions to suit different user categories.

Syrian Arab Republic
Al-Hawash Private University
Faculty of Engineering
Informatics Engineering Department



A Mobile Application for Detecting Counterfeit Currency Using Artificial Intelligence and Machine Learning Technologies

Graduation project prepared to obtain bachelor's degree of
Engineering - Informatics Department

Prepared by

Majd Samer Khalifa

Ali Adnan Mohammad

Supervised by

Dr. Eng. Mohammed Deeb

Academic Year

2025–2026